

Universidad Autónoma de Nuevo León

Facultad de Ciencias Fisicomatemáticas

Construcción y optimización de un portafolio que replique el IPC S&P/BMV mediante *clustering* y programación entera

Asesor: Beatriz Alejandra García Ramos

Práxedis Jiménez Ruvalcaba, Jonathan Torres Cárdenas

Resumen

Existen teorías y modelos económicos que se basan en hipótesis que no siempre reflejan las particularidades de mercados emergentes como el mexicano. En este trabajo se utiliza una combinación de técnicas de *clustering* y programación entera para construir un portafolio que replique el índice de precios y cotizaciones (IPC) S&P/BMV. Posteriormente, se evalúa su optimización mediante la *Modern Portfolio Theory* de Harry Markowitz, con el objetivo de analizar si este modelo estándar resulta suficiente bajo las condiciones del mercado nacional o si, por el contrario, es necesario desarrollar enfoques alternativos más adecuados para la realidad mexicana.

Abstract

Theories and economic models tend to be based in hypothesis which not always portray adequately the particularities of emergent markets as the Mexican. We used different techniques such as clustering and integer programming to build an investment portfolio which track the “índice de precios y cotizaciones” (IPC) S&P/BMV. Then we evaluated its optimization through Harry Markowitz’s Modern Portfolio Theory, with the objective of analyzing if this standard model is proper to be used on the national market, or if instead we should develop new alternatives adequate for the Mexican reality.

Introducción

Lo que se busca lograr es un fondo indexado a través del *quantitative portfolio managment* y en particular, del uso de la clusterización y la programación entera mixta para así conseguir maximizar las ganancias y reducir los riesgos de este. En general se busca adaptar el trabajo de Gharanchaei y Panda. (2024), adaptado al contexto particular de México.

No se busca un trabajo enfocado meramente a la inversión, sino que uno que a través de la *modern portfolio theory* (en particular, el trabajo realizado por Markowitz), y el marco en el que se constituye, podamos realizar comparaciones y

un análisis que nos permita un mayor entendimiento de nuestra economía y la naturaleza de nuestro mercado local. Lo cual, a su vez nos puede facilitar a comprender ciertos eventos y condiciones históricas.

Es común hallar trabajos que toman datos de países alejados de la realidad del nuestro, por lo que sus resultados también llegan a distar de nuestro contexto. Esto nos incita a pensar que existe un valor en adaptar otros trabajos, para ver si es aplicable en nuestra realidad y si no, ampliar su obra en otros contextos.

Revisión de literatura

Con *quantitative portfolio mangment*, nos referimos al uso de herramientas de la matemática para optimizar la gestión de activos. Siendo que este problema radica en dos; uno de clasificación (qué activos considerar) y uno de optimización (cuánto de cada uno), se usarán dos herramientas como lo son el clustering y la programación entera mixta.

Esta clase de herramientas ya han sido usado para este mismo tipo de problemas, por ejemplo, en problemas como *set covering* de Wolsey. (1998); Se utilizan conceptos de *clustering* (al clasificar conjuntos), en un problema de programación entera, solo que en este caso siendo algo para minimizar costos.

De forma más específica, también ya se ha trabajado con optimizar portafolios de inversión para máxima liquidez utilizando programación entera mixta como en Bertsimas *et al.* (1998). Incluso ha habido formas más recientes de trabajar con estas ideas utilizando herramientas actuales como lo son optimizadores, por ejemplo, Gurobi Optimizer en Kuhn. (2023). Aunque en este caso era un problema con un enfoque distinto al tener que ver más con administración gubernamental donde no importa maximizar ganancias tanto como reducir riesgos.

Sin embargo, el trabajo que más servirá y más se cita como referencia para esta clase de problemas en la literatura rescatada es sin duda alguna, el trabajo de Markowitz en 1952 de nombre *mean-variance* es hoy conocido mejor como *modern portfolio theory*. Donde describe y propone distintos modelos según ciertas propiedades, con el objetivo de obtener los mayores retornos con los menores riesgos. En particular describe tanto el *equally weighted*, por capitalización de mercado y de volatilidad mínima, además de la forma general de optimizar.

Hay que considerar el hecho de que el modelo de Markowitz posee varias limitantes. Como que considera que los rendimientos y en general, las ganancias que pueda generar un activo se distribuyan de manera normal, siendo que en economía las “colas gordas” en una distribución de probabilidad no son algo raro, algo que trabajos como el de Mainik, Georg *et al.* (2015) (Mainik, G., Mitov, G., Rüschen-dorf, L. (mayo, 2015). *Portafolio optimization for heavy tailed-tailed assets: Extreme Risk*

Index vs Markowitz. Elsevier.) señalan este limitante y maneras en las que podría mejorarse el uso de la optimización de Markowitz, el trabajo de Garachaei Y Panda (2024) que intentamos replicar, no toma alguna consideración especial con esto. Manteniendo una consistencia, ambos tendríamos la misma limitante.

Cabe destacar que tanto en el trabajo de Mainik, Georg. *Et al* (2015), como en el propio trabajo de Markowitz, Henry (1952) se destaca que una de la hipótesis del modelo es que la diversificación es la estrategia óptima. Esta hipótesis tiene raíz en que el modelo tiene el enfoque de diversificar para reducir el riesgo no sistémico. Esta hipótesis también termina por ignorar el riesgo sistémico, hecho por el cual es muy susceptible a este tipo de riesgo.

Entiéndase el riesgo sistémico como aquellos que afectan a todo el mercado, aunque no necesariamente a todos por igual. Un ejemplo de este riesgo pudiera ser la pandemia del COVID-19, recesiones, o eventos geopolíticos como cambios de gobierno, guerras armadas o comerciales. En contraposición, el riesgo no-sistémico es aquel que afecta a un sector, grupo o compañía en particular y que se evita a través de diversificación.

Trabajos como los de Michaud, Richard O. (1989) (Michaud, Richard O. (febrero, 1989). *The Markowitz Optimization Enigma: Is “optimized” optimal?* Financial Analyst Journal.) y Guo, Qi. (2022) (Guo, Qi. (2022). *Review of Research on Markowitz Model in Portfolios*. Advances in Economics, Business and Management Research, volume 215.) señalan otras limitantes importantes del modelo como el que está limitado a trabajar con datos estáticos en lugar de trabajar en base a predicciones, lo que añade un cierto sesgo además del propio como que los precios del mercado no reflejen un valor real. Tampoco toma en cuenta directamente aspectos macroeconómicos (inflación, producto interno bruto, poder adquisitivo, desempleo), ni estructurales (*momentum*, calidad, tamaño, crecimiento del mercado, se señala que son limitantes no despreciables. Sin embargo, el modelo sigue siendo un estándar y los trabajos que intentamos replicar, cuentan con estas mismas limitantes y aún así obtienen buenos resultados, como un error de seguimiento menor al 1% en un fondo indexado.

Un fondo indexado, como lo indica su nombre, es un índice que monitorea y mide los rendimientos de un conjunto particular de activos. Que en este caso sería el índice de precios y cotización de la bolsa mexicana de valores, que mide los rendimientos de 35 de las empresas más importantes de México utilizando como métrica la capitalización de mercado. La idea es tener un fondo con el que comprar activos imitando los rendimientos de un índice que mide un mercado en particular. La cual es una práctica común en casas de bolsa o fondos de inversión común.

La idea de realizar el trabajo con un fondo indexado en mente es que estos son muy diversos y que se construyen en base a una estrategia concreta, es decir, se elige un primer enfoque y el resto de las decisiones son una consecuencia de esta primera estrategia seleccionada. O, dicho de otra forma, es un enfoque pasivo. Lo cual dista de otros tipos de portafolios donde se requiere estar tomando decisiones de forma activa.

Existen trabajos que prueban una correlación entre maximizar las ganancias y minimizar los riesgos (Anderson *et al.*, 2011) y (Baker *et al.*, 2011), de forma que al realizar uno de los objetivos, implícitamente estás maximizando riesgos o minimizando ganancias. Dichos trabajos remarcan que existe evidencia para creer que mientras se minimicen los riesgos un efecto es la reducción de las ganancias.

Como ninguno de los enfoques sobre si maximizar ganancias afecta a los riesgos parece tener evidencia para descartar al otro. Además de que en los resultados de estos trabajos y nuestras referencias principales; Gharanchaei y Panda. (2024), Markowitz. (1952), muestran que maximizar ganancias minimiza el riesgo en cierta medida, pero esto se puede optimizar. Tendremos esta visión a la hora de trabajar con el problema.

El tomar la correlación como métrica para la clusterización tiene un fundamento teórico en economía, pues acorde a Koumou. (2020), una de las maneras de diseñar la correcta diversificación de un portafolio es agrupando a los activos con una correlación cercana a 1 y separando al resto. Esto reduce las probabilidades de que distintas agrupaciones tengan un mal desempeño al mismo tiempo, a esto se le conoce como *multilareal insurance*.

Tomamos la diversificación como algo bueno ya que, si bien Choueifaty y Coignard. (2008) muestran que existen diversos enfoques donde puede ser una estrategia no óptima, también se dan argumentos contrarios y que es más prominente las posibles ventajas que las desventajas. Además de que se remarca que los modelos no necesariamente reflejan la realidad del mercado, aunque puedan llegar a interpretarlo apropiadamente, y el éxito que pueda tener un modelo no debe de ser el único criterio para trasponerlo en el mundo real.

En nuestro caso, al estar imitando un índice, lo que buscamos es precisamente un modelo que refleje la realidad de un mercado y economía específicos. Esto por el interés de que todas las consideraciones en los trabajos citados son en un mercado competitivo y diverso, siendo esto algo distinto a la realidad del mercado mexicano el cual es monopolístico y poco diverso. Reed T; Muñoz Moreno, R. (2023).

Choueifaty y Coignard. (2008) enfatizan que no hay una sola medición que sirva para determinar la optimalidad de un modelo y es por ello por lo que todo trabajo de

índole bursátil, debe de contar con al menos dos enfoques distintos. Por ejemplo, existen argumentos válidos que favorecen a la varianza entre activos como una medida, pero también los hay que dicen que el interés compuesto es una mejor forma de determinar qué tan bien funciona el modelo.

En nuestro caso estaremos tomando el enfoque de las estrategias *equally weighted* ya que por Chow *et al.* (2011), y Carvalho *at al.* (2012), entendemos que, si bien se trata de una estrategia que antepone minimizar el riesgo a las ganancias, sigue siendo óptima además de que puede ser adaptada para asemejarse a otros tipos de estrategias que buscan diversificar, las cuales pueden llegar a ser más eficiente pero solo cuando se trata de reducir los costos, especialmente durante la inversión inicial.

A estas estrategias se les llama también *risk parity assest allocation* (Choueifaty y Coignard., 2008), que nuevamente es distribuir los “pesos” para distribuir el riesgo de manera equitativa. Siendo que el riesgo tiende a estar medido en volatilidad. Donde la volatilidad puede entenderse como qué tanto sube y baja de precio, por lo que podemos medirla como desviación estándar de los precios de una acción en un cierto período de tiempo.

Baker *et al* (2011), muestra que existen otras formas de medir la volatilidad dependiendo del tipo de activo y las consideraciones que se busquen tener, pero no es que exista una mejor forma que otra, sino que depende del contexto, aunque las formas más básicas tienden siempre a dar un acercamiento bastante acertado y por ello tomaremos la volatilidad como la desviación estándar de los precios de cierre en el período del tiempo de reajuste de los portafolios.

En ese mismo trabajo también se concluye que los portafolios diversificados son óptimos en comparación del resto, aun considerando un horizonte de tiempo real y distintas métricas. Koumou. (2020), Da argumentos a favor y en contra de la diversificación, pero su conclusión es también que la diversificación es una estrategia óptima. Por ello este es el enfoque en el que estamos abordando el problema.

Otra métrica que utilizaremos es la de la capitalización de mercado, la cual son las acciones en circulación de una empresa particular multiplicada por el valor que tienen dichas acciones de forma individual en dicho momento. Entonces la capitalización de mercado no es más que el valor total de las acciones de circulación.

La capitalización de mercado es una métrica muy usada porque te habla sobre la presencia que una empresa tiene en un mercado, entre más alta sea, más presencia tiene. A su vez, las fluctuaciones que pueda tener en un cierto tiempo te hablan

también sobre la volatilidad que dicha empresa. Ambas lecturas dan información tanto de si una empresa es representativa de un sector como del riesgo que pueda significar invertir en esta, por lo tanto, es de interés para nosotros además de que el índice que estamos intentando replicar esta medido con esta métrica.

El algoritmo que se quiere usar para el clustering es el de *partitioning around medoids*, Botyarov y Miller (2022); el cuál es semejante a *K-means* por tener una cantidad fija de centroides, pero sin usar la media aritmética y distancias euclidianas para relacionar a los elementos a un centroide, sino que, usando cualquiera otra métrica para medir la semejanza de los elementos con el centroide, que en este caso será la correlación.

En algunos trabajos los activos ya son un conjunto de otros activos que poseen una alta similitud entre sí, esto es solo para hacer más sencillo el seguimiento del desempeño de los activos, por el trabajo que se debe hacer de estar constantemente monitoreando y analizando los desempeños de estos activos. Por lo que cada activo asignado a un clúster es representativo de otro. Bajo esta misma lógica es que la cantidad de centroides se elige notablemente menor a la de activos totales. (Gharanchaei y Panda., 2024).

Descripción del problema

Hay dos enfoques con los que abordar el problema de replicar un índice; heurísticas y optimización. Las heurísticas es con las 3 fórmulas que serán mencionados a continuación del modelo para el clustering, pero se consiguen con base a la teoría y utilizan el concepto de *multilateral insurance*, así como las métricas de la capitalización de mercado y la volatilidad.

Mientras que el enfoque por optimización consiste en utilizar el trabajo de Markowitz, H. (1952), y usar sus algoritmos para mínima varianza y máxima ganancia, pero en una forma matricial y aprovechando los ya resultados proporcionados por las heurísticas, que en este caso nos estaremos refiriendo como *benchmarks*, las cuales serán las optimizadas.

El índice que intentaremos replicar con lo antes mencionado y posteriormente descrito es el S&P índice de precios y cotizaciones de la bolsa mexicana de valores (S&P IPC BMV), comúnmente abreviado como IPC.

Tomamos este índice ya que es uno de los principales indicadores de la economía mexicana, pues su comportamiento ha descrito apropiadamente el de nuestra economía y es una buena muestra de los principales sectores económicos de nuestro país. De mayor a menor proporción en el IPC se encuentran los sectores de servicio de telecomunicaciones, consumo frecuente, materiales, servicios financieros, industrial, servicio y bienes de consumo no básicos y salud.

El IPC es elaborado por la compañía S&P Dow Jones, la cual está enfocada en realizar índices de mercado. En este caso el IPC se elabora utilizando como métrica la capitalización de mercado de 35 empresas mexicanas S&P Down Jones (2025). (nota al pie de ref 14), las cuales son:

Empresas mexicanas parte del IPC	
Alfa S.A. A Alsea S.A. América Móvil S.A.B. de C.V. B Arca Continental S.A.B. de C.V. Banco del Bajío S.A. Becle S.A. De C.V. Bolsa Mexicana de Valores S.A. de C.V. Cemex S.A. CPO Coca Cola Femsa S.A.B. de C.V. UBL Corporación Inmobiliaria Vesta S.A.B. de C.V. El Puerto de Liverpool S.A.B. de C.V. Fomento Económico Mexicano S.A.B. de C.V. Genomma Lab Internacional S.A. de C.V. Gentera S.A.B. de C.V. Gruma S.A.B. B Grupo Aeroportuario del Centro Norte S.A.B. de C.V. Grupo Aeroportuario del Pacífico, S.A.B. de C.V. Grupo Aeroportuario del Sureste S.A.B. de C.V. B	Grupo Bimbo S.A.B. Grupo Carso S.A.B. de C.V. Grupo Cementos de Chihuahua S.A.B. de C.V. Grupo Comercial Chedraui S.A. de C.V. Grupo Financiero Banorte O. Grupo Financiero Inbursa O Grupo México S.A.B. de C.V. B Grupo Televisa S.A.B. CPO Industrias Peñoles Kimberly Clark de México S.A.B. de C.V. A La Comer S.A.B. de C.V. UBC Megacable Holdings S.A.B. de C.V. Orbia Advance Corporation S.A.B. de C.V. Promotora y Operadora de Infraestructura SAB de CV Qualitas Controladora S.A.B. de C.V. Regional S.A. de C.V. Walmart de México S.A.B. de C.V.

De esta lista de empresas cabe destacar también la distribución sectorial del índice, pero primero hay que aclarar que la manera en que se realiza la selección de empresas para el índice determina una cierta proporción sectorial para este, la cual es: bienes de consumo básico (29.8%), materiales (24.0%), servicios financieros (17.7%), industrias (14.5%), telecomunicaciones (10.4%), mercado inmobiliario (1.5%), consumo discrecional (1.5%), y salud (0.5%).

Sin embargo, esto solo indica la distribución sectorial en la selección, el peso en el que terminan estando representados distintos. Es en este nivel que el orden cambia a: telecomunicaciones, consumo frecuente, materiales, servicios financieros, industrias, consumo discrecional, y salud. Esto denota el gran peso que tienen algunas empresas, pues el que no se mantenga el mismo orden puede hablarnos

de una sobrerrepresentación, o el enorme tamaño de pocas empresas dentro de su mismo sector y la economía en general.

También cabe destacar que la propia S&P Dow Jones nos proporciona un listado que consiste en las diez empresas con mayor peso en el índice, así como su sector. En orden de mayor a menor peso según su numeración son:

1. Grupo México S.A.B. de C.V. B (materiales)	6. Walmart de Mexico S.A.B de C.V. (consumo básico)
2. Grupo Financiero Banorte O. (financiera)	7. Grupo Aeroportuario del Pacífico S.A.B de C.V. (industrias)
3. América Móvil S.A.B. de C.V. B (telecomunicaciones)	8. Industrias Peñoles (materiales)
4. Fomento Económico Mexicano S.A.B. de C.V. (consumo básico)	9. Grupo Aeroportuario del Sureste S.A.B. de C.V. B (industrias),
5. Cemex S.A CPO (materiales)	10. Arca Continental S.A.B de C.V.

Utilizando las librerías “yfinance” e “invest-corepy” en Visual Basic 1.99.3 con Python 3.12.7 integrado en el paquete de anaconda de versión 2.6.5, se obtuvieron los datos de los precios máximos, mínimos y de cierre, además de la cantidad en circulación de las acciones de las 35 empresas durante los períodos 2008 a 2010 y 2015 a 2024.

Inicialmente se consideró tomar este último plazo para probar cómo funcionan los distintos enfoques previamente mencionados en un período de diez años, específicamente el de ya que en 2010 se cambiaron algunas consideraciones al momento de medir el IPC, así que esas fechas poseen una metodología consistente de mediciones en el índice, además de que son fechas con crecimiento económico moderado, una recesión en 2020 y una recuperación en 2021 (nota a referencia 16).

Sin embargo, hubo un problema con los datos de algunas empresas y es que faltaban algunos datos. Siendo el peor caso el de Coca Cola Femsa S.A.B. de C.V. UBL, la cual no tenía datos completos hasta abril de 2019, por lo que, para tener datos completos de las 35 empresas en períodos consistentes, tuvimos que optar por iniciar el semestre de 2019 en abril, cerrarlo el último día junio y comenzar el siguiente semestre el primero de julio para cerrar en día último de diciembre, así para el resto de las fechas hasta el último de diciembre de 2024.

Si bien pasamos de un período de 10 años a uno de solo 5, no consideramos que sea un período despreciable o que inválide el trabajo. Si bien el trabajo de Grachaei y Panda (2024), abarca la década de 2014 a 2023, el cual fue un período con una recesión importante como la fue la del COVID-19. Además de un período

relativamente estable como el de 2014-2019 y uno de recuperación como el de 2021 a 2023.

Al menos en datos marco-económicos, el período 2014 a 2019 en Estados Unidos es uno estable con inflación media del 1.55% (World Bank Group. (2024). Inflation, cosnumers prices (anual %) – United States. [Base de datos].) y crecimiento del PIB medio del 2.55% (World Bank Group. (2024). GDP growth (anual %) – United States. [Base de datos].). Además de este período estable, tenemos la contracción del 2020 y la subida de la inflación en el 2021, junto con un proceso de recuperación seguido de uno de deinflación.

En México el período 2019-2024, que fue el que finalmente elegimos es también un período con relativa estabilidad en todos los años excepto el 2020, y ciertas consecuencias de la pandemia como la alza en la inflación. También es cierto que está inflación se desaceleró y bajó, y que en general México siempre ha tenido una inflación mucho mayor que aquella de Estados Unidos. En datos macro sin considerar 2020 tenemos un crecimiento medio del PIB del 2.82% (World Bank Group. (2024). Inflation, cosnumers prices (anual %) – Mexico. [Base de datos].) y una inflación media del 5.48% (World Bank Group. (2024). GDP growth (anual %) – United States. [Base de datos].). Cabe resaltar que el disparo de la inflación en la recuperación de la pandemia eleva este dato a comparación del previamente mostrado en el caso de Estados Unidos, ya que ahí no tomamos este período.

Así que nuestros horizontes de tiempo tienen comportamientos y eventos similares, como lo son la contracción del COVID-19, un período estable previo y una recuperación después de la pandémica acompañada de una subida en la inflación. Esto también es bueno para probar el modelo ya que sí en efecto la teoría posee una cierta robustez deberíamos conseguir resultados similares, tal vez no el mismo error, pero sí uno que consiga cumplir con el criterio de ser menor al 5%.

En la literatura se ha visto una práctica común y útil el probar modelos durante las crisis de 1929 y 2008, puesto que han sido de las más graves para Estados Unidos y ser capaz de tener poco error entonces indica una buena robustez para modelos o una buena certidumbre conforme la teoría que se esté probando. Por eso se compilaron datos del 2008, para poder probar, pero dados los resultados que obtuvimos y nuestra ventana de tiempo para elaborar el trabajo, se consideró innecesario este paso para poder concluir y se opta por dejarlo en algún proyecto futuro.

Además, los datos de 2008 para Banco del Bajío S.A., Becle S.A. De C.V., Coca Cola Femsa S.A.B. de C.V. UBL, La Comer S.A.B. de C.V. UBC, Qualitas Controladora S.A.B. de C.V. y Regional S.A. de C.V., están incompletos y no fue

posible completarlos. Así que también esto fue una razón para no haber probado el método de construcción del portafolio indexado para dicho período.

Los portafolios, excepto el del clustering y el *equally weighted* que por su naturaleza son fijos, van a estarse reajustando cada 6 meses. Lo ideal es tener distintos períodos para reajustarse, pero tomamos los 6 meses porque es la misma cantidad de tiempo en la que IPC se requilibra, entonces así tenemos una cierta consistencia entre nuestro portafolio y aquello que queremos imitar.

Los reajustes semestrales para la primera mitad serán partiendo 30 de junio para los años 2020, 2021, 2022 y 2023. 28 de junio de para 2019 y 2024. Mientras que para la segunda son el 31 para los años 2019, 2020 y 2021. 30 de diciembre para 2022, 2024. Y 29 de diciembre para 2023.

La primera parte del problema es obtener las correlaciones lineales entre acciones, puesto que será la métrica que usaremos para nuestra clusterización usando *partitioning around medoids*. Esto nos indicará cuáles son las acciones más representativas de cada clúster.

Seleccionamos la cantidad de 2, 4 y 8 clústers para realizar el *partitioning around medoids*, con base a proporciones acorde al trabajo de Gharanchaei y Panda (2024), ya que su trabajo considera 84 series de acciones de 5, 10 y 20 clústeres. Como nosotros consideramos solo 35 series de acciones, entonces estimamos las proporciones y así establecimos las cantidades de clústeres con las cuales trabajar el problema.

La manera en que queremos optimizar la clusterización es con uso de *mixed integer programming*, pues Gharanchaei y Panda (2024) describen un modelo con el cual contamos con variables enteras, pero nuestra función objetivo maximiza un número real el cual es la suma de las correlaciones de los elementos de los activos con su respectivo centroide.

$$\max \sum_{i=1}^n \sum_{j=1}^n c_{ij} x_{ij}$$

Sujeto a:

$$\sum_{j=1}^n y_j = k$$

$$\sum_{j=1}^n x_{ij} = 1 \quad \forall i$$

$$x_{ij} \leq y_j \quad \forall i, j$$

$$x_{ij}, y_j \in \{0, 1\}$$

Donde las variables toman sus valores acordes a lo descrito en la siguiente tabla:

c_{ij}	Similitud entre activo i y j. Es la correlación que existe entre ambos activos. Es un valor entre -1 y 1.
x_{ij}	Indica si el activo j del portafolio posee una alta correlación positiva al activo i. Toma el valor de 1 si este es el caso y toma 0 de lo contrario.
y_j	Denota qué activo j se encuentra en el portafolio tomando el valor de 1, de lo contrario es 0.
k	La cantidad de centroides, el cual como ya se explicó, debe de ser un número más chico que el total de activos porque se trabajará con representantes de la clase.

Ya tomando solo las acciones representativas, tenemos con qué medir el error, puesto que es como tomar los principales componentes el IPC. Y ahora podemos trabajar con el enfoque para resolver el problema a través de *benchmarks*, ya anteriormente mencionados en la revisión de literatura y que tomamos de Carvalho *at al.* (2012). Aunque son también mencionados por Markowitz, H. (1957).

Para mantener una consistencia con entre los *benchmarks* y el enfoque por optimización del trabajo de Markowitz, H. (1957), donde se destaca el considerar el problema sin tomar en cuenta la participación o las posibles decisiones que un asesor, corredor de bolsa o la experiencia y criterio que alguien pueda aportar, especialmente en cuestión probabilística, lo descartaremos. Solo tomaremos en cuenta los resultados directos.

Esto es una ventaja y debilidad de la optimización de Markowitz, pues el trabajar con datos estáticos nos facilita los cálculos y consideraciones que debemos realizar. Aunque esto lo vuelve débil al momento de intentar predecir un mercado real o trabajar con datos que no sean históricos.

Lo primero que haremos será un portafolio de tipo *equally weighted*. El cual es simplemente darles el mismo peso a todas las acciones para poder tener resultados consistentes con lo anteriormente planteado, y poder contrastar resultados, tomaremos 3 de estos modelos, empezando por el más general y antes mencionado:

Equally weighted

$$w_i = \frac{1}{n}$$

w_i	Peso del activo i , es decir, su importancia y cuánto debe de invertírsele en comparación del resto
n	Total, de activos

Este enfoque consigue una diversificación tal que maximiza la rentabilidad de la inversión con relación al riesgo que poseen los activos que se asumen. Simplemente es otorgarles el mismo peso o prioridad a todos los activos, que por la anteriormente *multilateral insurance*, termina por proporcionar un riesgo mínimo sin condicionar la ganancia máxima.

Equally Wighted es el *benchmark* más noble. Es simple de describir, operar, no requiere estarlo requilibrando en ningún momento. Y el no desplomar la ganancia a costa de reducir el riesgo, además de servir en cualquier mercado y ser fácilmente adaptable; lo ha vuelto una estrategia vencedora difícil de superar aún con métodos modernos (Edwards, Tim (enero, 2018). *Outperformance in Equal-Weight Indices*. S&P Dow Jones Indices: Index Investment Strategy.).

El otro *benchmark* sería el del *market-cap*, el cual asocia cada activo acorde a su capitalización del mercado, el cual es el producto de acciones en circulación con su precio actual.

$$w_i = \frac{M_i}{\sum_j^n M_j}$$

Donde

$$M_i = x_i p_i$$

M_i	Capitalización del mercado de la compañía i . Puede entenderse como una métrica con la cual evaluar la viabilidad de invertir en una compañía. Cocientando esta medida con la suma de todas podríamos saber cuál es la proporción con la que debemos invertir en cada compañía.
x_i	Cantidad de acciones circulando en el mercado de la compañía i
p_i	Precio actual de las acciones de la compañía i

De los *benchmark* que estamos considerando, es el que tiende a ofrecer menos liquidez. Es en cierta forma muy segura y cambia muy poco, pues al generar poco, uno tarda en reinvertir los dividendos generados por la inversión anterior. Sin embargo, esto no debería afectar su efectividad al momento de construir el portafolio indexado, sino que, al contrario, pues se seleccionó este enfoque porque es con el que el IPC también se elabora (S&P Dow Jones Indices. (febrero 2025). *S&P/BMV Indices: Metodología*.).

Lo que plantea el *benchmark* es invertir proporcionalmente a la capitalización de mercado, entre más alta sea, más habrá que invertir. Ya que esto asegura estar invirtiendo acorde a las propias proporciones del mercado y así tomar solo acciones

representativas por lo que reduces el riesgo. Tener activos en las empresas más grandes de cada sector es considerado como una estrategia a veces excesivamente segura, de ahí viene su usual poca ganancia, pero gran reducción de riesgo.

Al momento de medir la capitalización de mercado los datos que tenemos son las acciones en circulación en un cierto momento. No disponemos de la información necesaria para saber si algunas de esas acciones son *inside trading*, es decir, al intercambio privado entre accionistas o miembros de la compañía de acciones. Por lo que consideraremos que todo lo que está en circulación es abierto para todo el público o todo el mercado accionario al menos.

El último enfoque del tipo de diversificación que estamos trabajando y usaremos es el que se basa en la volatilidad como métrica. Reiterando algo mencionado previamente, en este caso mediremos la volatilidad con la desviación estándar de los precios de un activo. El modelo en cuestión es:

$$w_i = \frac{\frac{1}{\sigma_i}}{\sum_j^n \frac{1}{\sigma_j}}$$

σ_i	Volatilidad del activo i . La desviación estándar de su precio.
------------	---

Se trata de un caso particular puesto que, en condiciones concretas, llega a ser de lejos el más eficiente de los 3 modelos, pero en general se trata de un enfoque centrado en favorecer los activos de bajo riesgo, pero teniendo rendimientos más similares al primer modelo y de hecho siendo a veces muy similar a este.

La manera en que funciona es simplemente con proporciones. El activo con mayor riesgo es el que menos peso deba tener en el fondo indexado, mientras que el de menor riesgo va a tener el mayor peso. Esto nos da una certidumbre al momento de minimizar el riesgo, pero lo consigue llegando a reducir considerablemente las ganancias.

Para asignar el peso de la acción representativa de cada clúster en el portafolio final, tenemos la expresión:

$$x_{jl} = \frac{\sum_{i \in C_l} w_i}{\sum_{l=1}^n w_i}, \quad l = 1, \dots, k$$

Donde k es el total de los clústeres

w_i	Peso de la acción asignado por alguno de los <i>benchmark</i>
C_i	Clúster i
l	Cantidad de clústeres

x_{jl}	Peso de la acción representativa j en el clúster l
----------	--

Lo que se realiza aquí es determinar la proporción que cada acción debería de tener en cada uno de los clústeres que se determinaron al inicio, acorde al peso asignado por alguno de los *benchmark* anteriormente discutidos. Por eso es la suma de los pesos de un cierto clúster, entre la de del total de clústeres.

Este proceso de asignación de pesos por clúster debe de realizarse para poder construir el portafolio indexado y trabajar apropiadamente con el modelo de optimización de Markowitz, el cuál debería de optimizar la varianza en base a los rendimientos de dicho portafolio indexado. Pero antes de revisar el modelo de optimización, es importante ver cómo se estará midiendo el error.

Para esto, se utilizará son los rendimientos del portafolio que construimos con respecto a los rendimientos del IPC. El rendimiento de un activo puede entenderse como la proporción en que cambia el valor de este durante un cierto período. Se representa de la siguiente forma forma:

$$r_i = \frac{V_i - V_{i-1}}{V_i}$$

r_i	Rendimiento de un activo en un momento i , o al fin de un período i .
V_i	Valor de cierre de un activo en un momento i , o al fin de un período i .

En nuestro caso los períodos serían los semestres, por lo que, para los valores del activo, se tomaría el precio de cierre de una acción al inicio y al final del semestre para así obtener el rendimiento que tuvo ese activo. Ese rendimiento después debe ser multiplicado por el peso de la acción. La media de los rendimientos multiplicada cada uno por el peso de la acción a la que corresponde, es el rendimiento del portafolio que construimos.

Podemos ver que el rendimiento es una proporción, la cuál nos indica qué tanto creció o se contrajo el valor de algo. De la misma forma que se obtiene el rendimiento para un activo, se obtiene el del IPC, solo que en este caso basta con solo realizar el cociente y la diferencia con los valores de cierre mensuales del IPC del primer y último mes del semestre.

Al comparar los rendimientos, estamos comparando el comportamiento del índice y de nuestro portafolio. No nos interesa que nuestro portafolio siempre tenga rendimientos altos, sino que buscamos reducir la varianza en la diferencia de los rendimientos. Que ambos crezcan y se contraigan al mismo ritmo. Esto es lo que nos permitiría tener un fondo indexado, que con pocas acciones seamos capaces de darle seguimiento a un índice de forma pasiva.

Entonces por cada período el error se medirá como la diferencia entre los errores, es decir, los rendimientos de nuestro portafolio menos los rendimientos del IPC. Esta diferencia si es positiva es porque los rendimientos fueron mayores a los del IPC, y si son negativos es el caso contrario. Minimizar esta diferencia es lo que buscaremos con el modelo de optimización de Markowitz.

Es por esto por lo que la manera de medir el *tracking error*, o error de seguimiento, puede expresarse de la siguiente forma:

$$TE = devstd(R_B - R_{IPC})$$

TE	Error de seguimiento de nuestro portafolio al índice
R_B	Vector de rendimientos del portafolio con las acciones representativas de cada clúster dado un <i>benchmark</i> ,
R_{IPC}	Vector de rendimientos del IPC

El error de seguimiento no es más que la variabilidad de las diferencias entre los rendimientos durante todos los semestres que estamos considerando. Por eso calculamos la desviación estándar de lo ya mencionado.

Intentar minimizar esa diferencia, es lo que reduce el error de seguimiento y es para lo que vamos a utilizar el modelo de optimización de Markowitz. Cabe destacar que existen estándares que determinan lo que es un buen error y uno aceptable. El consenso dictamina que debajo del 0.5%, el portafolio es excelente al replicar el índice (*BAJAJ Asset Managment. (s.f.). Understanding Tracking Error: How It Impacts Your Investment Strategy. [Base de datos]*). Se varía entre si debajo del 1% o del 2% es un buen error, pero normalmente se establece que debajo del 1% el modelo sigue siendo efectivo (*Sumit, Naurla., Prateek, Pandey. (noviembre 2025). Tracking error index funds. AXIS MAX Life Insurance*). Encima del 1% es un error considerable para un fondo indexado, especialmente por el hecho que se administran de manera pasiva, si se tratase de un fondo administrado de manera activa, un error del 5% seguiría siendo aceptable y nuestra cota máxima por un modelo efectivo. (*Graham, Hand. (april, 2022). Track if your fund manager is taking the best shot. Morningstar*).

Para optimizar los portafolios anteriormente realizados con los *benchmarks* reduciendo el error de seguimiento, tomaríamos como referencia el siguiente modelo planteado por Choueifat y Coignard. (2008):

$$\min(X - X_B)^T M (X - X_B)$$

Sujeto a

$$1^T X = 1$$

$$X \geq 0$$

$$|x_{B,i} - x_i| < \text{máximo turnover}$$

$$\sum_{i=1}^n |x_{B,i} - x_i| \leq \text{máximo turnover}$$

X	Es nuestra variable, el portafolio optimizado que deseamos construir. Un vector donde el peso de los activos representativos de la <i>clustering</i> son sus variables.
X_b	El vector con los pesos de las acciones representativas obtenidos a través de alguno de los <i>benchmarks</i> .
M	Matriz de covarianzas de los rendimientos del índice con las del portafolio.
<i>Máximo turnover</i>	Se refiere a la proporción máxima de cambio que la optimización del portafolio está condicionada a tener.

En este caso se trabajó la optimización por período, justo como se presenta el modelo, es decir, la optimización del portafolio se hizo por separado durante cada rebalanceo. Esto porque así es como lo plantean Choufety y Coingard (2008), no proponen un modelo alternativo ya que como se había mencionado, Markowitz trabaja con datos estáticos y desde un enfoque determinístico por lo que casos anteriores no son de interés.

El máximo *turnover* determina qué tanto puede cambiar el portafolio, cuál es la proporción en qué puede hacerlo. Se dice que para que un fondo indexado mantenga su naturaleza pasiva, el *turnover* debería ser del 5% (Drenovak, Mikica., Rankovic, Vladimir. (2014). *Markowitz portfolio rebalancing with turnover monitoring*. Faculty of Economics, University of Kragujevac. Economic Horizons, Volume 16, Number 3, 207-217.). Aunque el *turnover* de hasta 15% sigue siendo aceptado en ocasiones (Mansa, Julius. (octubre 2025). Understanding Annual Turnover: Definition, Formula, and Examples. Investopedia.).

Así que, las últimas dos restricciones nos marcan que el cambio de cada acción debe ser menor a una cota de *turnover*, y que la suma de la proporción de todos los cambios debe ser menor igual a dicha cota.

La primera restricción es para que se invierta todo el portafolio, es decir que la suma de las proporciones de cada activo (los pesos), sea uno. Esto porque el problema está pensando como un portafolio completo sin un hueco que deba ser llenado de alguna forma particular. Mientras que la segunda restricción es para no vender todo un activo, ya que precisamente esto podría presentar un problema al momento de

considerar los rendimientos, además es una restricción que vimos en el resto de modelos similares que revisamos como el de Garanchaei y Panda (2024).

La ecuación (#ec de función objetivo) podemos notar resulta en un polinomio de grado igual a la cantidad de clústeres y cuya minimización altera los pesos asociados con los rendimientos de la matriz de covarianza. Se tiene entendido de Markowitz (1954) que el modelo fija alguna variable, como los rendimientos en orden de minimizar la varianza de estos.

En este caso no es un modelo que optimice solo la varianza dado un portafolio, sino que busca reducir la varianza en relación con la diferencia de los rendimientos entre un índice y un portafolio, por esta razón es que es necesaria la matriz de covarianzas. Más aún, como buscamos hacerlo en base al portafolio dado por el *benchmark* es que tomamos la diferencia del nuevo y este.

Experimentación y análisis de resultados

Todo fue realizado en una laptop con sistema operativo Microsoft Windows 11 Home Single Language, Versión 10.0.26100, de marca Acer y modelo Aspire AV15-53P, con un procesador de décima tercera generación Intel Core(TM) i5-1335U, 1300 Mhz. Una memoria física instalada (RAM) de 16 GB, y un BIOS Insyde Corp V1.09.

Generación de instancias (Si necesito que cheques esta sección y agregues lo que falta).

El código fue realizado en un jupyter notebook de Python, de manera que cada casilla correspondía a una parte distinta del proceso. Primero se tuvo que elaborar el código que utilizando las librerías de “yfinance” e “invest-corepy” para poder extraer los datos diarios de las acciones de cada una de las 35 empresas del IPC listadas anteriormente.

La información de cada empresa era organizada en un *dataframe* con las columnas que indicaban la fecha, el precio de cierre de la acción, el precio máximo, el mínimo y la cantidad de acciones en circulación. En ese preciso orden se ordenaban para posteriormente guardarse en un archivo CSV.

Después se volvían a leer los archivos y se iban guardando los datos en un mismo *dataframe*, solo que organizando los nombres de cada columna de manera que indicaban qué dato eran y de cuál empresa. Cabe resaltar que todos los datos tenían las mismas fechas, por la que no había problemas al momento de ir concatenando los *dataframes*. Además de esto se guardaban dos copias del *dataframe*, excepto que una solo poseía las columnas que indicaban el precio de cierre.

Es con este último es que se obtenían las correlaciones lineales entre los precios de todos y con dichos datos hacíamos el *clustering* en el modelo (#ec modelo

clustering), aprovechando el optimizador Gurobi (versión 12.0.0). Esto nos daba un archivo de texto el cual indicaba los activos representativos por clúster y a qué clúster eran asignados cada otro activo. Los activos representativos los escribía manualmente en una lista por cluster que se guardaría en memoria. También de forma manual se hacía una lista que guardaba la separación de cada semestre, cuándo iniciaba uno y cuándo terminaba otro. Además de otra que hacía lo mismo para los datos del IPC, los cuales eran mensuales.

También se indexaba la copia del *dataframe* que no se había utilizado, con las fechas como índice, esto para la siguiente celda que se encargaba de conseguir los pesos que debía tener cada uno de los activos seleccionado a través del *clustering*, durante cada semestre. De manera que se guardaba todo en una lista de listas, que poseía el peso de cada activo durante un semestre determinado. Se guardaba una lista de los pesos acorde a la capitalización de mercado, utilizando el *benchmark* (*#ec market cap*) y otra con los de la volatilidad usando el *benchmark* (*#ec volatilidad*).

Cabe resaltar que se debía determinar manual la cantidad de clústeres, para que el programa determinase los pesos, no era necesario especificar las empresas, pero sí la cantidad de clústeres. Ya después de esto se calculaba el error el error en otra celda. Pero primero hay que destacar que para el *benchmark equally weighted* (*#ec EW*), no era necesario realizar un cálculo más que obtener el inverso multiplicativo del total de activos, que en este caso se trataba de la cantidad de clústeres.

Aquí falta realmente todo lo que me ayudaste a hacer y bueno, eso incluye correcciones a lo anterior. No corregí esta parte porque creo que es mejor con lo que viste tú que en realidad tienes la totalidad del código más fresca que yo, excepto la parte de jalar los datos, esa creo que se mantendría

El modelo de Markowitz fue construido con ayuda de la librería de Gurobi y seguía al pie la expresión (*#ec modelo Markowitz*). Sin embargo, como el modelo solo servía para obtener el portafolio optimizado en un cierto período, se optó para hacer una función recursiva que imprimiese el portafolio optimizado en todos los períodos dados los parámetros como el *benchmark* y la cantidad de clústeres. El modelo propiamente llamaba a otras funciones para obtener el vector de pesos del *benchmark*, así como la matriz de covarianza y transformarlos en arrays que Gurobi pudiese leer.

Los resultados se imprimían con primero toda la información propia que considera Gurobi, seguidos del portafolio con los pesos optimizados y el portafolio original, una tabla que mostraba los cambios de peso por acción y la proporción en que el portafolio cambio, es decir, el *turnover*.

Se copiaban estos campos y pegaban en un archivo txt junto con los resultados del resto de períodos. Esto ya que se optó que era mejor hacer esto y tener un registro guardado de todos los resultados, en lugar de llamar una función cada que se necesitase alguno en particular. Además, por hacerlo por período y organizarlo en arrays, esto iba a generar un conflicto con el resto de las funciones y de datos.

Después, para que tuvieran el mismo formato se fueron armando listas copiando y pegando los resultados tanto del turnover como los nuevos portafolios en un notebook, el cual organizó los datos en listas compatibles con lo que teníamos. Teniendo esto listo, se organizó una función que llamase a estos datos para ahora poder calcular el error de los nuevos portafolios, así como graficarlos, a parte de también realizar las gráficas del turnover.

Primero se realizó todo este proceso para las instancias en que la cota del *turnover* era del 90%, para mirar cómo se comportaba dicha métrica y si se contenía dentro de los estándares de un fondo indexado ya mencionados, es decir, debajo del 15% o el óptimo de un pasivo siendo 5%.

Después solo se construyeron las funciones para graficar todo esto, además de elaborar las gráficas comparando los diferentes portafolios entre sí. Estas gráficas, además de las del *tracking error* total de cada una. Fue lo último que se realizó y éstas fueron llamadas a través de funciones recursivas y guardadas de manera manual en una carpeta, para su posterior uso presentando los resultados.

Resultados

Las siguientes tablas representan los resultados obtenidos por el *clustering*, cada tabla es el resultado de una selección distinta de centroides. Recordemos que decidimos tomar 2,4 y 8 centroides.

Empresas representativas para 2 clústeres	
Grupo Financiero Banorte O.	Grupo Televisa S.A.B. CPO
Grupo Bimbo S.A.B. Cemex S.A. C.P.O Alsea S.A. Arca Continental S.A.B. de C.V. Banco del Bajío S.A. Grupo Carso S.A.B. de C.V. Coca Cola Femsa S.A.B de C.V. UBL Corporacion Inmobiliaria Vesta S.A.B. de C.V. El Puerto de Liverpool S.A.B. de C.V.	Alfa S.A. A. Banco del Bajío S.A Bolsa Mexicana de Valores S.A. de C.V. Industrias Peñoles Megacable Holdings S.A.B. de C.V. Orbia Advance Corporation S.A.B. de C.V.

Fomento Economico Mexicano S.A.B. de C.V. Genomma Lab Internacional S.A. de C.V. Gruma S.A.B. B Gentera S.A.B. de C.V. Grupo Aeroportuario del Centro Norte S.A.B. de C.V. Grupo Aeroportuario del Sureste S.A.B. de C.V. B Qualitas Controladora S.A.B. de C.V. Regional S.A. de C.V. Grupo Cementos de Chihuahua S.A.B. de C.V. Grupo Comercial Chedraui S.A. de C.V. Grupo Financiero Inbursa O. Grupo Mexico S.A.B. de C.V. B Kimberly Clark de Mexico S.A.B. de C.V. A La Comer S.A.B. de C.V. UBC Grupo Comercial Chedraui S.A. de C.V. Walmart de Mexico S.A.B. de C.V.	
---	--

Empresas representativas para 4 clústeres			
Bolsa Mexicana de Valores S.A. de C.V.	Genomma Lab Internacional S.A. de C.V.	Grupo Financiero Banorte O.	Grupo Televisa S.A.B. CPO
Becle S.A. De C.V. Industrias Peñoles La Comer S.A.B. de C.V. U.B.C.		Grupo Bimbo S.A.B. Cemex S.A. C.P.O. Alsea S.A. America Movil S.A.B. de C.V. B Arca Continental S.A.B. de C.V.	MegacableHoldings S.A.B. de C.V. Orbia Advance Corporation S.A.B. de C.V.

		Banco del Bajío S.A. Coca Cola Femsá S.A.B de C.V. UBL Corporación Inmobiliaria Vesta S.A.B. de C.V. El Puerto de Liverpool S.A.B. de C.V. Fomento Económico Mexicano S.A.B. de C.V. Gentera S.A.B. de C.V. Gruma S.A.B. B Grupo Aeroportuario del Centro Norte S.A.B. de C.V. Grupo Aeroportuario del Sureste S.A.B. de C.V. B Grupo Carso S.A.B. de C.V. Grupo Cementos de Chihuahua S.A.B. de C.V. Grupo Comercial Chedraui S.A. de C.V. Grupo Financiero Inbursa O. Grupo México S.A.B. de C.V. B Kimberly Clark de México S.A.B. de C.V. A Qualitas Controladora S.A.B. de C.V. Regional S.A. de C.V.	
--	--	--	--

		Walmart de Mexico S.A.B. de C.V.	.
--	--	----------------------------------	---

Empresas representativas para 8 clústeres							
Alfa S.A A	Americ a Movil S.A.B. de C.V. B	Arca Contine ntal S.A.B. de C.V.	Bolsa Mexicana de Valores S.A. de C.V.	Genomma Lab Internacion al S.A. de C.V.	Grupo Carso S.A.B. de C.V.	Grupo Mexico S.A.B. de C.V. B	Grupo Televis a S.A.B. CPO
		Grupo Bimbo S.A.B. Banco del Bajío S.A. Coca Cola Femsa S.A.B. de C.V. UBL El Puerto de Liverpool S.A.B. de C.V.. Grupo Comercial Chedraui S.A. de C.V. Grupo Financiero Banorte O Grupo Financiero Inbursa O	Becle S.A. De C.V. Industrias Peñoles Qualitas Controladora S.A.B. de C.V.	.	Alsea S.A. Corporación Inmobiliaria Vesta S.A.B. de C.V. Fomento Económico Mexicano S.A.B. de C.V. Gentera S.A.B. de C.V. Gruma S.A.B. B Grupo Aeroportuario del Centro Norte S.A.B. de C.V.	Cemex S.A. C.P.O. Grupo Cementos de Chihuahua S.A.B. de C.V. La Comer SAB de CV UBC	Megacable Holdings S.A.B. de C.V.

		Grupo Comerci al Chedrau i S.A. de C.V. Regiona l S.A. de C.V. Walmart de Mexico S.A.B. de C.V.			Grupo Aeroportu ario del Sureste S.A.B. de C.V. B Kimberly Clark de Mexico S.A.B. de C.V. A		
--	--	--	--	--	---	--	--

A primera vista lo que podemos notar de estas tres tablas es que no fueron clústeres con una distribución uniforme, en los tres casos hubo uno que posee notoriamente más elementos que el resto y en el caso de 2 y 4 clústeres fue la misma empresa; Grupo Financiero Banorte O, la cual es la segunda institución financiera más grande del país ([Grupo Financiero Banorte. \(s.f.\). Empresa: Acerca de Banorte. Banorte.com](#)). Mientras que en el caso de 8 clústeres se repartió mayormente todo entre Arca Continental S.A. de C.V. y Grupo Carso S.A.B de C.V. siendo la primera productora, distribuidora y comercializadora de Coca Cola en México y de “snacks” en países como el propio México, Ecuador y Estados Unidos. ([Arca Continental. \(2025\). Acerca de Nosotros. Arcacontal.com](#)). Y la segunda es un conglomerado diverso que principalmente opera en el sector comercial, industrial, infraestructura y energía. ([Grupo Carso \(2020\). Acerca de Nosotros. Carso.com](#)).

En el caso particular de los 2 clústeres, destaca precisamente el cómo Grupo Financiero Banorte aglomera la gran mayoría, mientras que el clúster de Grupo Televisa si es bien es casi 7 veces más chico, esto no lo hace muy uniforme en cuanto a las empresas que agrupa, pues hay dos instituciones financieras (Banco del Bajío S.A. y Bolsa Mexicana de Valores S.A. de C.V.), una química (Orbia Advance Corporation S.A.B. de C.V.), una también química pero con actividad importante en el sector minero (Industrias Peñoles, una enfocada en alimentos (Alfa S.A A) y la única que empata en sector con Grupo Televisa, siendo Megacable Holdings. Así que tenemos dos clústeres bastantes diversos en sectores, pero desiguales en tamaño.


La siguiente agrupación de 4 clústeres destaca que el de Grupo Financiero Banorte se mantiene del mismo tamaño, y es más bien el de Grupo Televisa el que cede elementos ante los demás, siendo que el clúster de Genomma Lab Internacional S.A. de C.V. uno sin ningún elemento más que el propio centroide. Mientras que el nuevo clúster con la Bolsa Mexicana de Valores S.A. de C.V. de centroide, es


bastante diverso al contar con empresas que forman parte de sectores como el minero, financiero, supermercados y la producción de tequila.

Nuestra última iteración para ahora 8 clústeres presenta las agrupaciones más diversas, ya que, si bien siguen las empresas sin distribuirse de manera uniforme, al menos ahora hay dos clústeres con tamaños más iguales (10 sin contar el centroide), siendo Arca Continental S.A.B de C.V. el centroide para la mayoría de las instituciones financieras (enfocadas a la banca) y comercializadoras. Mientras que Grupo Carso S.A.B de C.V. aglomera una gran diversidad de sectores como alimentario (Alsea S.A. y Gruma S.A.B B), instituciones financieras (Gentera S.A.B de C.V. y Fomento Económico Mexicana S.A.B. de C.V.), aeropuertos y productos de limpieza (Kimberly Clark de México S.A.B. de C.V. A.).

En esta última iteración también podemos observar que las dos empresas de cementos (CEMEX S.A. C.P.O. y Grupo Cementos de Chihuahua S.A.B. de C.V.) quedaron en el mismo clúster con Grupo México S.A.B de C.V. B, la cual es una empresa con una gran presencia en la infraestructura mexicana. Y otras dos empresas que comparten sector como lo son Megacable Holdings S.A.B de C.V: y Grupo Televisa S.A.B. de C.V, terminaron en el mismo clúster. En contraposición La Bolsa Mexicana de Valores S.A. de C.V. termino con empresas que habían estado rotando entre clústeres en las iteraciones anteriores y que no tienen mucho en común. Dejando los clústeres de Alfa S.A. A y America Movil S.A.B. de C.V.

A continuación, se presentan las mediciones de error de los portafolios que solo toman en cuenta los pesos dados por los *benchmark* y no se optimizó con Markowitz. C2, C4 y C8 significan las agrupaciones con 2, 4 y 9 clústeres respectivamente y EW significa *Equally Weighted*. Primero revisemos los gráficos del error de seguimiento del índice dado un cierto *benchmark*.





De Aquí podemos destacar una serie de patrones que van a repetirse en el resto de nuestros resultados y es la manera en que se dispara el error en la primera mitad del 2020, período el cual fue el inicio de la pandemia de COVID-19 y presentó varios desafíos entre los cuales fue una incertidumbre en los mercados (Solís y Arias, J. Valentín. Et al. (2022). *Impacto de la crisis de 2020 en la economía mexicana: un enfoque de insumo-producto con inoperabilidad*. Problemas del desarrollo. ISSN 0301-7036.) y un riesgo sistémico de mercado. También podemos ver otros picos de error en el primer semestre de 2022 y en el primero de 2023.


El primero de estos períodos tuvo un crecimiento del 1%, con una subida de la inflación de más del 6%, según World Bank Group (2024). Sin embargo, ninguna de las cifras es del todo alarmantes por lo que provoca algo de extrañeza ese error. A nivel estructural del mercado, Banco de México (2025) (Banco de México. (2025). *Informes trimestrales*. [Base de datos].) en sus informes trimestrales de los períodos enero-marzo, abril-junio y julio-septiembre, destaca que el mercado en general tiene un efecto de recuperación sostenido y que reacciona de buena forma a la reapertura de la economía china y repunte de la estadounidense. Señala tal vez como mayor problema la inflación subyacente de la recuperación y la subida de los precios en los alimentos consecuencia de la guerra entre Rusia y Ucrania.

El segundo período netamente en economía fue un período de crecimiento con desaceleración del .09% en julio y una desaceleración de la inflación en julio al 3.5% anual (Secretaría de Hacienda y Crédito Público. (enero, 2024). *Comunicado No. 5 Informes sobre la Situación Económica*, las Deuda Pública al cuatro trimestre de 2023. Prensa.) (Cámara de diputados LXV legislatura. (noviembre 2023). *Análisis sobre la Situación Económica al Tercer Trimestre de 2023*. Centro de Estudios de las Finanzas Públicas.) Banco de México (2025) en los informes trimestrales de los períodos enero-marzo, abril-junio y julio-septiembre, destacan que la reducción de la inflación está

siendo mayor de lo prevista y que los mercados y economía mexicana muestran una buena recuperación acorde lo históricamente resiliente que ha mostrado ser nuestra economía, pero que también se debe al remudamiento de las cadenas de producción. Aunque cabe destacar que las cifras son buenas y en niveles muy normales y no un caso de recuperación acelerada o lenta como en otros países, o así lo destaca el informe trimestral de abril-junio. Así que nuevamente estamos frente a buenos parámetros que no salen fuera de lo normal y aún así el error es alto.

En general también podemos observar que la diferencia entre dos y cuatro clústeres no es mucha, sin embargo, la diferencia con 8 clústeres es bastante notoria. Si bien no se deshace de los picos, sí son suavizados y todo cae en una banda de error en la que podemos decir que en algunos períodos como la segunda mitad de 2021, se da un seguimiento preciso al IPC S&P/BMV.


Ahora revisamos el error de seguimiento en cada período según cada clustering



Aquí lo primero que resalta es que, en efecto, entre más clústeres se reduce el error, al menos, los picos no llegan al mismo máximo que el anterior. También destaca nuevamente que el comportamiento es muy similar con 2 o 4 clústeres, no solo el error


en general, sino que también el error de todos tiene un compartimiento similar. Es con 8 clústeres que el comportamiento cambia y se marca una diferencia mucho más clara entre las mediciones de cada benchmark con ciertos períodos mantenido una cierta similitud.

Ahora analicemos el error (desviación estándar de los errores por período) de seguimiento de cada benchmark según la cantidad de clústeres.






Hay que recordar que se habla de un buen error de seguimiento cuando esté es menos de .01 o en ocasiones debajo del .02 o .05, por lo que ninguno de los errores consiguió un seguimiento satisfactorio del índice. Aún así, el paso de 2 clústeres a 8 redujo en casi la mitad el error, lo cual sí es significativo. Esto resalta el hecho que no hay una reducción tan significativa del error entre 2 y 4 clústeres.

A continuación, se muestran las mediciones del error, pero ahora comparando benchmarks según cada clustering






La capitalización de mercado posee notoriamente un error mayor al resto en los clustering de 2 y 4, sin embargo, es con 8 clústeres su error es el menor. Además, podemos ver que excepto por la ligera diferencia de error en el clustering de 8, es la volatilidad quien mantuvo un mejor seguimiento del IPC.

Primero vamos a mostrar los resultados obtenidos por el portafolio de Markowitz que se dejó con una cota de turnover del 90%, ya que se supone que con un cambio libre debería de poder darnos un portafolio de una varianza mínima capaz de reducir el seguimiento del índice con menor error que solo el benchmark. Vamos a presentar las gráficas en el mismo orden y después discutiremos sobre los resultados del turnover.






A diferencia del portafolio sin optimizar podemos ver que la diferencia entre cada clustering es notoria cómo disminuye el error conforme aumentan los clústeres. Los picos del error son casi los mismos excepto porque aquí el error se dispara todo el primer año de la pandemia, en lugar de solo el primer semestre, lo cuál podría ser la susceptibilidad de Markowitz a errores sistémicos.








Como en el caso anterior, no podemos notar a simple vista quién posee un menor error, lo que sí podemos ver es la enorme reducción del error entre las primeras dos iteraciones. Mientras que entre las siguientes podemos notar como decrecen algunos picos y especialmente cómo la capitalización de mercado reduce mucho sus picos de 2022 en adelante, pero crece su error bastante en el primer período de 2021, superando su error en el clustering anterior, lo cual es inusual. Intuitivamente se podría decir que más clústeres permitieron que la optimización redujese el error no sistemático, pero lo volvieron precisamente más susceptible a ello, es decir, le dieron más margen a la optimización de Markowitz de trabajar.






Corroboramos la manera dramática en que se reduce el error agregando 2 clústeres, pero también podemos apreciar que la reducción del error de 4 a 8 clústeres no es tan grande, más aún, con la capitalización de mercado podemos relacionar el cómo casi no decrece el error con el cómo redujo sus picos en un período, pero los aumentó en otro, cosa que ya discutimos. También podemos apreciar que no se llega al estándar aceptable de .05, por lo que sigue sin ser una buena forma de dar seguimiento al IPC.



Comparando los benchmarks, corroboramos la reducción drástica entre 2 y 4 clústeres, pero también notamos que la capitalización de mercado comenzó siendo la de menor error, pero no continuó esa tendencia, mientras que la volatilidad e equally weighted se mantuvieron siempre relativamente cercanos, con esta última siendo la que obtuvo menos error en la última iteración.

Sobre el turnover según el tipo de benchmark, primero hay que tomar en cuenta que como se mantuvo un mismo clustering durante todos los períodos, el equally weighted fue igual siempre, por lo que el turnover también hizo eso, lo cual fue cuanto menos extraño, ya que los rendimientos no eran los mismos siempre. No se pudo realizar una revisión que nos permitiese determinar cuál fue la razón de esto.



Primero cabe aclarar el detalle del turnover de la capitalización de mercado y es que se muestra de esta manera y notación distinto al resto de gráficas, ya que siempre se aproximó bastante cerca al cambio de 0.9, por lo que al ser números tan cercanos los unos de los otros la gráfica tuvo que adaptarse a otra escala, escala en la cual vemos que casi todo funcionó igual excepto en el primer semestre de 2021 y el último 2023, los cuales con 8 clústeres fueron los períodos con más error y uno con una buena

lectura de error respectivamente, por lo que llama bastante la atención y de nuevo nos invita a pensar en las limitantes de Markowitz y las diferencias entre error sistémico y no-sistémico.

El hecho de que el turnover en la capitalización de mercado se acercase tanto a 0.9 sin serlo del todo tiene que ver con la manera en que Python opera flotantes de cierto tamaño. Ya que al varias de las operaciones que realiza Gurobi terminan en resultaos decimales, estos empiezan a poseer números “basura” o escorias que por el modelo mantener las restricciones (#restricciones turnover), se ve condicionado a llegar a ese tipo de números.

Es de interés revisar el por qué no se cambió equally weighted de maneras desiguales. Tendría sentido que en dos clustering siempre se fue al máximo, pero el por qué en el tercero se fijó a un límite de 0.82 es de interés. Aunque si bien es cierto, no era un límite totalmente igual en los datos numéricos, aunque esto podría deberse a la manera de trabajar números flotantes demasiado grandes, cosa que pudo también pasar en la capitalización de mercado y que causó que la gráfica no se viera uniforme.

La volatilidad fue sin duda quien presentó más diversidad de cambios, en particular con cuatro clústeres solo tuvo un cambio menor 0.9 y extrañamente teniendo menos cambios con solo dos clústeres, siendo que aquí poseyó un error mucho mayor. Con 8 clústeres solo presentó dos períodos con cambio de 0.9, siendo ambas sus fechas con mayor error, mientras que la de menor cambio fue la de menor error.


Cabe recordar que para un fondo indexado pasivo como el que buscamos construir el turnover debería estar a los más en 0.15, una cifra que ninguno consiguió de manera natural, por lo que decidimos realizar una prueba con una cota de 0.10 ya que sería el punto medio entre la cota máxima permitida y la óptima de 0.05 y ver cómo funcionaba. Los resultados de acotarlo se presentarán más adelante.

No se consideró tomar solo la de 0.05 ya que al estar presentando cambios tan grandes de manera natural y cómo en trabajos como el de Garachaei y Panda (2024) se toma el *turnover* como una cierta métrica de error. Ver cuánto se alejaba el portafolio del *benchmark* del óptimo, queremos seguir dándole cierta cabida. No se realizó una segunda prueba con otra cota porque se consideró suficiente con los resultados obtenidos. Además que un cambio del .05 donde el 0.10 y el 0 no ofrecieron algo cercano a un óptimo deseado, parecía algo redundante.

Los resultados del turnover con respecto a cada clustering no nos brindaron mucha información en particular, más allá de ya notoria diferencia entre como cada

benchmark tuvo maneras de comportar sus cambios sumamente distintas. Por lo tanto, no vamos a añadir dichas gráficas.

Ahora revisemos las comparaciones entre los errores entre los portafolios con los Benchmarks y los optimizados con Markowitz, según cada Clustering.




Resaltan hechos como la reducción dramática entre 2 y 4 clústeres de la versión con Markowitz, en comparación de la poca reducción de error que tienen los benchmarks bajo ese cambio de clustering. De manera análoga los benchmarks tienen una reducción importante del error entre los 4 y 8 clústeres, cosa que no tuvieron las versiones con Markowitz, por lo que al final de portafolios con una optimización de Markowitz no acotada, terminan con un error mayor que los portafolios con solo el benchmark. Siendo equally weighted el único benchmark que consiguió tener un error menor en su versión optimizada en la última iteración.




Esto nos habla precisamente de que la optimización con Markowitz falla. A pesar de conseguir formar portafolios más diversificados y que posean rendimientos similares, pero con una mínima varianza, así reduciendo el riesgo no-sistémico, esto no crea un

seguimiento mejor del índice. Por lo que los resultados del trabajo de Garanchei y Panda no parecen aplicar para el caso concreto de la economía mexicana.



A continuación, mostraremos los resultados que obtuvimos acotando el turnover al 0.10 que es el estándar para fondos indexados pasivos. Continuaremos exponiendo los resultados en el mismo orden.




Notemos que en general el comportamiento es el mismo entre las versiones sin haber usado Markowitz. Tal vez solo cambia que en la volatilidad se nota una mayor reducción general del error y que los picos de Equally Weighted a partir de 2022 se vuelven mucho más agresivos en el clustering de 4 pero en general se preservan las tendencias.





Comparando benchmarks entre clusterings notamos que se mantienen las tendencias y el comportamiento sigue siendo el mismo. La única diferencia se puede notar especialmente en el clustering de 8 y es que todos los picos son más chicos, es un cambio ligero, pero se puede notar como todo queda dentro de una banda más estrecha.






A diferencia de cuando comparamos el error por clustering entre nuestros portafolios sin optimizar con Markowitz y los no acotados, podemos ver que las acotadas prácticamente siempre tuvieron un error menos. Con 2 clústeres casi no hay diferencias y con 4 clústeres la versión acotada de Equally Weighted posee más error que el portafolio sin optimización, pero para los 8 clústeres todos poseen un notorio menor error en relación con su contraparte sin optimizar.

Si bien las versiones optimizadas con un turnover acotado poseyeron un error menor en el clustering de 8, también es cierto que este sigue sin llegar a ser menor de 0.05 que es la cota superior para establecer que se realizó un buen seguimiento. Numéricamente no se llega a apreciar en la gráfica, pero todos poseyeron un error mayor al 0.07. Así que aún con Markowitz acotado seguimos sin obtener una forma satisfactoria de construir un portafolio indexado para IPC S&P/BMV.





Finalmente comparando todos los portafolios entre sí por clustering, podemos apreciar que para 2 y 8 clústeres, el portafolio optimizado con cota de 0.10 en su turnover obtuvo menores errores o semejantes a los demás. Sin embargo, no fue siempre el más eficiente a dar seguimiento al IPC, pues la versión sin cota fue notoriamente mejor en el clustering de 4.

En general todos estos resultados muestran que la optimización con Markowitz no nos es consistentemente más útil que solo usar el benchmark, ni nos da una razón de asegurar que una versión sin acotar sea mejor a una versión con cota. Simplemente nos muestra que la teoría no es lo suficientemente sólida para el mercado mexicano y las conclusiones en el trabajo de Garanchaei y Panda no aplican del todo para nosotros, dado que no obtuvimos muchos resultados que mantuvieran una cierta consistencia.

Lo único consistente fue la reducción de error en el portafolio del benchmark con el aumento de activos representativos, lo cual era algo de esperar. Dado que entre más componentes del IPC tomes, debería de aumentar la certeza con la que se le da seguimiento. Pero el punto de un fondo indexado es poder hacerlo con el mínimo de activos posibles y cambiando lo menos entre cada período de rebalance, cumpliendo con un cierto error de seguimiento. Nada de esto se logró cumplir para ninguna de nuestras pruebas.

Particularmente con los portafolios optimizados no hubo nada de lo cual poder garantizar algún resultado. Es precisamente esta clase de inconsistencia la que nos motiva a preguntarnos cómo falla Markowitz y qué deberíamos trabajar en su lugar. Es por esto por lo que creemos vale la pena revisar nuevas teorías que se adapten más a la realidad del mercado mexicano.

¿Por qué si Garanchaei y Panda (2024) consiguieron métricas satisfactorias en todos los *benchmarks* realizando el procedimiento que nosotros replicamos, nosotros no estamos pudiendo cumplir con ninguna convención? Para responder esto habría que pensar precisamente en las diferencias que tuvieron nuestros trabajos, muchas de las cuales ya se destacaron, así cómo se señaló si no tendrían realmente impacto.

El período de tiempo fue distinto, pero bien se señaló que era necesario tener diversos escenarios dentro de este como una contracción, recuperación y período estable. Siendo que los primeros dos fueron los mismos períodos. Así que el horizonte de tiempo no pareciese ser el fallo.

La selección de clústeres fue de cantidades distintas pero proporcionales a lo que habían hecho, además que, en nuestro caso, no se mantuvo siempre el hecho de que, a mayor cantidad de centroides, menor error de seguimiento cuando se aplicaba la optimización de Markowitz. Por lo que pareciese ser que, en parte, hay un fallo aquí.

También hay que destacar los picos de error al inicio de 2022 y 2023, siendo que como ya se mencionó, no se encontró nada que denotase un valor fuertemente atípico a nivel macroeconómico. Lo que sí se terminó por hallar fue una caída drástica en las exportaciones en enero de 2022, así como una caída menor de las importaciones, según INEGI (2025), (INEGI (2025). *Balanza Comercial*. [Base de datos].) además de otra caída, aunque mucho menor en 2023, también siendo la reducción en exportaciones mucho mayor que la de importaciones. Aún así, cabe resaltar que a inicios de 2024 esto también ocurrió, además siendo mayor que en 2023 y este período no presento un error tan elevado como estás dos.

Volviendo a la optimización de Markowitz, como ya se había mencionado antes, el resto de trabajos poseen las mismas limitantes que nosotros aquí. Si bien Guo, Qi. (2022) menciona cómo agregar restricciones al modelo evita muchas de estas limitantes, nosotros agregamos las mismas restricciones en nuestra implementación de (*#ec de Markowitz*). Además, también trabajamos con datos históricos y estáticos, suponiendo que los rendimientos se distribuyen de manera normal y con que el modelo no cuenta con información macro y estructural.

Que, por lo anterior, no pareciese que a nivel macro se encuentre el problema, al menos con la información que pudimos recompilar y la capacidad de análisis con la que contamos. Así que la única diferencia pudo ser en factores estructurales del mercado o eventos sociopolíticos.

Con este último no contamos precisamente con las herramientas para elaborar un veredicto concreto de qué maneras pudo haber influido, ya que, si bien es cierto que los errores en mayores se dieron en períodos convulsos a nivel nacional, no

podimos hallar alguna forma de relacionar alguno de estos eventos a los resultados que obtuvimos. En cualquier caso, esto valdría la pena revisarse a más detalle en el futuro y si el error yace aquí, seguiría corroborando nuestra hipótesis de que es necesario un modelo capaz de operar propiamente dada la realidad nacional.

Discutiendo las componentes del IPC y los sectores que lo integran se hizo notar que este no es muy diverso en comparación de otros índices como el NASDAQ100 del trabajo que buscamos replicar. Esta es una diferencia importante que compete a la estructura del mercado nacional.

Así mismo, el hecho de que sectores con mucho peso como materiales o telecomunicaciones tuvieran tan solo tres representantes cada uno nos muestra una situación en la cual un problema entre pocas empresas podría percibirse en el modelo como un problema sistémico. Como tenemos pocas emisoras de acciones dominantes en sectores de peso, el riesgo total es cercano al riesgo propio de estas, es decir, un riesgo no sistémico se transforma en uno sistémico, que una optimización de Markowitz no es capaz de reducir.

Siendo esto último, donde vemos con más certidumbre dónde podría estar el fallo de la optimización de Markowitz en nuestro trabajo, sin embargo, no podemos asegurar que se trate de esto solo con las métricas y análisis que realizamos. Nos limitamos a probar que, replicando ciertos trabajos, fallaría su implementación en la economía mexicana dado lo distinta que es a economías industriales como la estadounidense o australiana donde se realizaron algunos de estos trabajos.

Queda para trabajos futuros el realizar correcciones y agregados que se han destacado a lo largo de este escrito como probar otras iteraciones o variables, obtener datos precisos de la cantidad de acciones en circulación de cada empresa, ampliar el horizonte de tiempo, pero también queda el revisar otras métricas como: el Information Ratio para medir el exceso de retorno por unidad de tracking error, Expost TE que mide qué tan estable fue la replicación del índice (varianza del exceso de retorno), Beta relativa que si es cercana a uno se sigue bien al benchmark y si no hubo desalineamiento estructura.

Otra sugerencia a futuro sería profundizar en la manera en que factores sociopolíticos pudieron haber influenciado el error en nuestras lecturas. Revisar fenómenos y eventos tanto a nivel nacional como internacional. Pues ya anteriormente Banco de México (2025) destacó en el informe trimestral julio-septiembre de 2023 que la guerra entre Rusia y Ucrania ciertamente estaba afectando la economía y mercado nacional.

Estas revisiones nos deberían permitir concluir de manera más concisa dónde yace el error propiamente y más aún, nos deberían dar un punto inicio desde el cuál poder

elaborar propuestas de modelos los cuáles sirvan y se adapten propiamente a la realidad de la economía y el mercado nacional.

Conclusión

Siendo el modelo de optimización de Henry Markowitz (1952) un estándar al momento de optimizar portafolios, replicamos el trabajo de Garanchaei y Panda (2024) y a pesar de tener las mismas limitantes propias del modelo, no conseguimos ninguna métrica satisfactoria que nos permita concluir que esta optimización pueda aplicarse de manera efectiva con el objetivo de construir un portafolio indexado al IPC S&P/BMV, sino que al contrario, muestra varias inconsistencias que nos permiten concluir que este modelo de optimización no es suficiente para trabajar en el mercado nacional. Es por esto por lo que es necesario realizar trabajos futuros los cuales puedan identificar la causa concreta de dónde falla el modelo al adaptarlo y si es necesario modificarlo o desarrollar nuevos enfoques.

Referencias

1. Gharanchaei, M. K., Panda, P. P. (2024). *Constructing and investment fund thourg stock clustering and integer programming*. Journal of Advancements in Applied Business Research.
2. Wolsey Laurence, A. (1998). Formulations. *Integer Programming*. (pp. 1-18). Wiley Interscience.
3. Bertsimas, D., Darnell, C., Soucy, R., (1998). Portfolio construction through mixed integer programming. MIT.
4. Kuhn, C. C. N., Calbert, G., Garanovich, I. L., Weir, T., (2023). *Integer linear programming supporting portfolio design*. Elsevier.
5. Markowitz, H. (1952). *Portfolio selection*. JSTOR. (pp 77- 91).
6. Knutzen, S., Retterholt, J., (2015). *Performance of risk-based asset allocation strategies* [tesis master, Copenhagen Business School].
7. Anderson, R. M., Bianachi, S. W., Goldberg, L. R. (2011). *Will My Risk Parity Strategy Outperform?* Berkeley.
8. Baker, M., Bradley, B., Wurgler, J. *Benchmarks as Limits to Arbitrage: Understanding the Low-Volatility Anomaly*. Financial Analysts Journal.
9. Botyarov, M., Miller, E. E., *Partitioning around medoids as a systemic approach to generative design solution space reduction*. Elsevier.
10. Choueifaty, Y., Coignard, Y. (2008). *Toward Maximum Diversification*. The Journal of Portfolio Management.

11. Chow, T., Hsu, J., Kalesnik, V., Little, B., *A Survey of Alternative Equity Index Strategies*. Financial Analysts Journal.
12. Carvalho R. L., Lu, X., Moulin, P. (2012). *Demystifying Equity Risk-Based Strategies: A Simple Alpha plus Beta Description*. The Journal of Portfolio Management.
13. Koumou, G. B. (2020). *Diversification and portfolio theory: a review*. Swiss Society for Financial Market Research.
14. S&P Dow Jones Indices. (31 marzo 2025). S&P/BMV IPC: *Constituents Export*. [Base de datos].
15. S&P Dow Jones Indices. (febrero 2025). *S&P/BMV Indices: Metodología*.
16. Banco de México. Sistema de Información Económica [Base de datos].
17. Reed, T; Muñoz Moreno, R. (febrero 23, 2023). How the Federal Economic Competition Commission fights for workers and consumers in Mexico. World Bank.
18. Sánchez Deanny (octubre 6, 2023). Antitrust in Mexico: Perspectives, challenges, and opportunities.
19. Bacaria Colom, Jordi (2018). *La nueva presidencia de México: entre la incertidumbre y la esperanza*. Barcelona Center for international affairs